

基于多变量 LSTM 的空气质量预测

23375371 林孜

Linzi_15762331896@buaa.edu.cn

摘要

本文基于 Kaggle 数据的北京 PM2.5 空气质量数据集，开展了多变量 LSTM 模型的时序预测研究。数据包含 2010 年至 2014 年逐小时的 PM2.5 浓度及露点、温度、气压、风向、风速、累计降雪与降雨等气象变量。针对数据的时序特性和年度周期特征，按年份顺序将数据集划分为训练集（前 3 年）、验证集（第 4 年）和测试集（第 5 年）。在预处理阶段，对风向类别变量采用独热编码，对数值特征进行最小-最大归一化，并通过滑动窗口方法构建监督学习样本。模型方面，以 LSTM 网络为核心，通过网格搜索确定最优超参数组合（时间窗口 18 小时、隐藏单元 64、单层结构），并引入 dropout 正则化与梯度裁剪策略控制过拟合风险。实验结果表明，模型在测试集上取得了 RMSE 为 0.0268、 R^2 为 0.9192 的预测性能，验证集与测试集指标高度一致，模型泛化能力良好。进一步采用 SHAP 方法进行可解释性分析，结果显示历史 PM2.5 浓度贡献最大，风向特征次之，其中西北风和东南风的 SHAP 值显著高于其他气象变量，表明模型有效捕捉了风向与污染物区域输送之间的关联；而降雨、降雪等稀疏特征的贡献较低。综合预测精度与可解释性分析，多变量 LSTM 模型能够有效融合气象信息进行 PM2.5 时序预测，且模型内部决策逻辑与大气物理机制基本吻合。

关键词： 长短期记忆网络；空气污染预测；多变量时序预测；SHAP 可解释性分析；独热编码

一. 引言

时间序列预测是监督学习中的重要分支，其目标是根据历史观测数据，学习一个从过去时间窗口到未来取值的映射函数，从而对未知时刻的目标变量进行预估。即给定历史序列 $\{\mathbf{X}_{t-L}, \mathbf{X}_{t-L+1}, \dots, \mathbf{X}_{t-1}\}$ ，预测模型旨在学习假设函数 $f: \mathbb{R}^{L \times d} \rightarrow \mathbb{R}$ ，使得未来时刻的预测值 $\hat{y}_t$ 尽可能逼近真实值 y_t 。

时序预测的重要性体现在多个方面。首先，它是众多现实应用的核心技术，如空气质量预警、交通流量预测、电力负荷调度和金融风险评估等^[1,2]。其次，时序预测任务中普遍存在的长期依赖、多变量耦合、周期性模式等挑战，推动了以长短期记忆网络（LSTM）为代表的深度学习架构的持续演进^[1]。LSTM 通过引入记忆单元和门控机制，有效缓解了传统循环神经网络在处理长序列时的梯度消失问题，能够捕获时间跨度超过 1000 步的长程依赖关系。此外，空气质量预测直接关系到公众健康防护与政府环境治理决策，具有显著的社会应用价值^[4]。

本研究采用的数据集源自 Kaggle 数据库的北京 PM2.5 空气质量数据，时间跨度为 2010 年至 2014 年共五年，包含逐小时的 PM2.5 浓度及露点、温度、气压、风向、风速、累计降雪与降雨等气象变量。基于该数据的以往分析表明，北京 PM2.5 浓度的变化受气象条件的显著影响，且呈现出复杂的非线性波动特征^[5]。从时序特性来看，污染物的累积与扩散受多种气象因素的交互影响，且存在显著的日周期及季节周期性特征，PM2.5 浓度的变化规律本质上是非线性的。近年来，已有研究将 LSTM 与傅里叶分解、WaveNet 等方法结合用于 PM2.5 预测，验证了 LSTM 在多变量空气质量预测任务中的有效性^[3]。

本文工作如下：基于原始数据按年份顺序划分为训练集、验证集和测试集，通过独热编码与归一化预处理后，构建滑动窗口监督样本；以 LSTM 网络为核心模型，利用训练集学习多变量时序模式，在验证集上调整超参数，最终在测试集上评估预测性能，并结合模型原理与数据特征对结果做出解释。

二. 算法原理

2.1 长短期记忆网络（LSTM）

长短期记忆网络（Long Short-Term Memory, LSTM）是一种特殊的循环神经网络（RNN），由 Hochreiter 和 Schmidhuber 于 1997 年提出，专为解决传统 RNN 在处理长序列时出现的梯度消失和梯度爆炸问题而设计^[1]。其核心思想是通过引入记忆单元和

门控机制，使网络能够选择性地记住或遗忘信息，从而有效捕获时间序列中的长期依赖关系。

传统 RNN 在反向传播过程中，梯度经过多次连乘后会呈指数衰减或增长，导致网络难以学习远距离的时间关联。LSTM 通过精心设计的三个门——遗忘门、输入门和输出门——来控制信息的流动，使得梯度可以在长时间跨度上稳定传播^[1]。结构如下图所示。




图 1 LSTM 结构

LSTM 单元在时刻 t 接收当前输入 x_t 和上一时刻的隐藏状态 h_{t-1} 、记忆单元 c_{t-1} ，通过以下机制更新状态。

遗忘门决定从记忆单元中丢弃哪些信息：

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

输入门决定哪些新信息存入记忆单元：

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$\tilde{c}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c)$$

记忆单元根据遗忘门和输入门的结果进行更新：

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$

输出门决定记忆单元的哪些部分输出到隐藏状态：

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$$

$$h_t = o_t \odot \tanh(c_t)$$

其中 $\sigma(\cdot)$ 为 Sigmoid 激活函数，输出值域为 $[0, 1]$ ； $\tanh(\cdot)$ 为双曲正切函数，输出值域为 $[-1, 1]$ ； $\odot$ 表示逐元素乘积； W 和 b 为可学习的权重矩阵与偏置项。遗忘门 f_t 控制旧信息的保留程度，输入门 i_t 控制新信息的写入程度，输出门 o_t 控制记忆

内容的暴露程度。三个门的输出值均在 $[0, 1]$ 之间，0 表示完全阻断，1 表示完全通过。

从 LSTM 方法可以发现，该方法适用于具有长期依赖关系的时序预测问题。相比于传统 RNN，LSTM 的门控结构有效缓解了梯度消失问题，使得捕获长程依赖成为可能；相比于 Transformer 等架构，LSTM 的参数效率更高，适合中等规模数据集^[1]。然而，LSTM 的串行计算特性限制了其训练并行度，且对输入特征的尺度较为敏感，需进行归一化预处理。

2.2 评价指标

为了在后续的模型评估中保持评价标准的一致性，本文选取均方根误差（RMSE）、决定系数（ R^2 ）作为核心回归评估指标。

设测试样本数为 N ，第 i 个样本的真实值为 y_i ，预测值为 $\hat{y}_i$ ，各项指标定义如下。

均方根误差（Root Mean Squared Error, RMSE）为 MSE 的平方根，将误差还原至原始量纲：

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2}$$

决定系数（Coefficient of Determination, R^2 ）衡量模型预测结果相较于均值基准的改进程度：

$$R^2 = 1 - \frac{\sum_{i=1}^N (\hat{y}_i - y_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2}$$

其中 $\bar{y} = \frac{1}{N} \sum_{i=1}^N y_i$ 为真实值的均值。

在上述指标中，RMSE 将误差还原至与原始数据相同的量纲， R^2 反映模型对目标变量方差的解释比例，取值越接近 1 表明拟合效果越好。本文综合使用上述两项指标，从不同角度评估模型的预测性能。

三. 原始数据分析与处理

3.1 数据集分析

原始数据为从 Kaggle 下载的连续五年（2010–2014）空气质量与气象逐小时观测数据，数据包括：date，pollution（PM2.5 浓度），dew（露点），temp（温度），press（气压），wnd_dir（风向），wnd_spd（风速），snow（累计降雪小时数），rain（累计降

雨小时数)，时间粒度为 1 小时。

首先绘制数据中 PM2.5 浓度随时间变化的散点图，如下。从图中能够清晰看出 PM2.5 的浓度变化呈现出以一年为周期的近似周期变化。冬季浓度较高，夏季浓度较低。这与我们的认知吻合。




图 2 PM2.5 浓度随时间变化图

3.2 数据集划分

由于数据具有时序特征，训练集、验证集和测试集的划分需要保持时间的连续性，不能采用随机切分的方式。同时，考虑到空气质量及气象数据存在以年为周期的季节性特征，为保证各子集在时间维度上包含完整的周期信息，我们按年份顺序进行划分，确保每个子数据集有一年完整数据：将原始 5 年数据中前 3 年的数据作为训练集（60%），第 4 年的数据作为验证集（20%），最后 1 年的数据作为测试集（20%）。

3.3 类别特征编码

原始数据中的风向（wnd_dir）为类别型变量，包含 SE、NW、cv 等风向类别，无法直接输入模型。为保留完整的类别信息且不引入虚假的序关系，本文采用独热编码（One-Hot Encoding）进行处理。

设风向变量共有 k 个可能的取值，对每个取值 $c_i \in \{c_1, c_2, \dots, c_k\}$ ，编码后生成一个 k 维二值向量：

$$\mathbf{o}_i = [0, \dots, 1, \dots, 0] \in \{0, 1\}^k, \sum_{j=1}^k o_{ij} = 1$$

其中仅有对应类别位置为 1，其余为 0。编码后风向特征由 1 维扩展为 k 维，与其他数值特征拼接后共同输入模型。

3.4 数值特征归一化

数据集中各数值特征的量纲和取值范围差异显著。若直接输入模型，量级较大的特征将在梯度更新中占据主导地位，影响模型收敛速度和预测精度。

为此，本文采用最小-最大归一化（Min-Max Scaling）将各数值特征线性映射至

0-1 区间:

$$x'_i = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}}$$

其中 $x_{\min}$ 和 $x_{\max}$ 分别表示该特征在训练集中的最小值和最大值。验证集和测试集使用训练集上拟合的缩放器参数进行变换，以避免信息泄露。

特别地，目标变量（pollution）使用独立的归一化器进行处理，与特征缩放器分离。这样在后续评估阶段，可将预测值独立反归一化至原始量纲：

$$\hat{y}_i = \hat{y}'_i \times (y_{\max} - y_{\min}) + y_{\min}$$

从而保证预测结果具备实际的物理解释性。

3.5 监督学习样本构造

原始数据为连续的时间序列，需要转换为可供 LSTM 学习的监督格式。本文采用滑动窗口方法构建输入-输出样本对。

设特征矩阵为 $\mathbf{X} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_T\}$ ，目标序列为 $\mathbf{y} = \{y_1, y_2, \dots, y_T\}$ ，时间步总数为 T 。设定回望窗口长度为 L ，则每个样本的构建方式为：

$$\mathcal{D} = \{(\mathbf{X}_{t-L:t}, y_t)\}_{t=L}^T$$

其中 $\mathbf{X}_{t-L:t} = [\mathbf{x}_{t-L}, \mathbf{x}_{t-L+1}, \dots, \mathbf{x}_{t-1}] \in \mathbb{R}^{L \times d}$ 表示过去 L 小时的 d 维特征序列， y_t 为当前时刻的 PM2.5 浓度标签。模型通过学习前 L 小时的特征模式，预测下一小时的污染水平：

$$\hat{y}_t = f_{\theta}(\mathbf{x}_{t-L}, \mathbf{x}_{t-L+1}, \dots, \mathbf{x}_{t-1})$$

经窗口构建后，样本形状从原始时序格式 (T, d) 转换为三维张量格式 (N, L, d) ，其中 $N = T - L$ 为有效样本数。这一格式与 LSTM 等循环神经网络所要求的输入维度完全适配。

综上几步，完成训练前的数据处理。

四. 实验研究

4.1 实验超参数选择

实验具有多个超参数，其中 `epochs`、`batch_size` 等常规参数在前面几次作业中展示过其选取过程，这里不再赘述。这里我们选取与 LSTM 紧密相关的时间窗口长度、LSTM 单元数、LSTM 层数三个参数展示在报告里。其余参数会在验证集测试，但不再在报告中展示。

4.1.1 时间窗口长度

测试时间窗口为 12, 14, 16, 18, 20, 24, 48, 最终得到的 RMSE 如下。

表 1 RMSE 随时间窗口长度变化

时间窗口长度	12	14	16	18	20	22	24	48
测试 RMSE	0.031	0.033	0.029	0.028	0.030	0.031	0.032	0.034

因此时间窗口为 18h 时，测试准确率最高，因此取为 18。

4.1.2 LSTM 单元数

LSTM 单元数取 32, 64, 128, 测试得到 RMSE 如下。

表 2 RMSE 随 LSTM 单元数变化

LSTM 单元数	32	64	128
测试 RMSE	0.02685	0.02680	0.02698

因此看到，最终结果 LSTM 单元数为 64 时最小。因此单元数取为 64。

4.1.3 LSTM 层数

LSTM 层数对比 1, 2, RMSE 如下。

表 3 RMSE 随 LSTM 层数变化

LSTM 层数	1	2
测试 RMSE	0.02680	0.02941

因此层数取 1。

4.1.4 最终参数选择

经过测试，得到实验最终参数如下表所示。

表 4 实际选择超参数

超参数	准确率
学习率	0.001
Batch_size	64
Dropout	0.2
时间窗口长度	18
LSTM 单元数	64
LSTM 层数	1

跟据该参数，进行下一步实验。

4.2 最优参数实验

4.2.1 实验结果

根据选取的最优超参数，训练后在测试集上测试，得到 RMSE 和 R^2 。最终数据如下。

表 5 最优参数测试结果

RMSE	R^2
0.02680	0.9192

4.2.2 实验分析

首先绘制 RMSE 与训练轮数区别，训练集与验证集 RMSE 随 epoch 先下降后趋稳，模型在验证集最优点附近停止，说明已收敛并通过早停抑制过拟合。并且能看到 val 和 train 数据集预测差别不大，说明没有模型没有过拟合。这是由于我们训练时对模型在配置上对过拟合风险进行了多方面的控制。首先，模型容量适中，采用单层 LSTM 结构且隐藏单元数设为 64，在表达能力和复杂度之间取得了较好的平衡，避免了因参数过多而过度拟合训练数据。其次，在 LSTM 层后设置了 dropout=0.2 的正则化机制，通过训练时随机丢弃部分神经元，降低了模型对训练集局部细节的过度记忆。此外，学习率设置为 0.001、批量大小为 64，并配合梯度裁剪策略，使得训练过程中的参数更新幅度保持稳定，不易因剧烈震荡而进入过拟合区域。




图 3 RMSE 随 epoch 变化

再绘制真实值与测试集上预测值对比图。测试集预测曲线整体跟随真实 PM2.5 变化趋势，表明模型对下一时刻污染浓度具有较好的拟合与泛化能力，说明我们选择的超参数较优。但是在 PM2.5 剧烈变化的时间点上，预测并不到位，这是符合预期

的。这一结果表明，尽管模型能够有效提取 PM2.5 序列的整体演变规律，但在面对短时、突发的极端变化时，预测精度仍有所不足。导致该问题的原因可能来自两个方面：极端样本在整体训练数据中所占比重偏低，使得模型在优化过程中更倾向于拟合占据主导地位的常规模式，对尾部极端变化的刻画能力相应受限；而且突发性高浓度事件往往由多种瞬态因子耦合驱动，而当前输入特征集合未必完整涵盖此类短时扰动信息。




图 4 真实值与测试集对比

4.3 shap 分析

针对训练后的深度学习模型，目前主流的可解释性分析方法主要包括三类：其一是基于局部近似的 LIME 方法，通过在预测点附近用简单可解释模型逼近原模型行为，但其解释结果的稳定性受局部采样范围影响较大；其二是基于梯度反向传播的显著性图方法，直接计算输出对输入的梯度以反映特征敏感度，但梯度噪声较多，且敏感度不等同于实际贡献度；其三是基于博弈论 Shapley 值的 SHAP 方法。SHAP 将模型对单个样本的预测值分解为各输入特征的贡献之和，具有坚实的公理化数学基础，能够同时提供全局特征重要性和局部样本解释，且对任意黑箱模型均适用。相较于 LIME，SHAP 的解释结果满足一致性和可加性，更为稳定可靠；相较于梯度归因方法，SHAP 度量的直接反映特征对预测值的实际贡献，而非仅是局部敏感程度。鉴于上述优势，本文选用 SHAP 方法对训练后的多变量 LSTM 模型进行可解释性分析。

shap 分析数据，看各个参数的 shap 值，绘制图如下。数据填在表中。




图 5 各特征 shap 图

表 6 各特征 shap 值表

特征	平均绝对 shap 值
pollution	4.26×10^{-3}
wnd_dir_NW	5.46×10^{-4}
wnd_dir_SE	3.91×10^{-4}
temp	3.37×10^{-4}
dew	3.05×10^{-4}
wnd_dir_cv	2.93×10^{-4}
wnd_dir_NE	2.61×10^{-4}
snow	8.68×10^{-5}

历史 PM2.5 浓度（pollution）的 SHAP 值为 4.26×10^{-3} ，在所有特征中居于首位，且远超其余特征。这一结果反映出 PM2.5 序列本身具有强自相关性，模型主要依靠污染物浓度在时间上的延续性进行预测，这与大气污染物在稳定条件下具有累积性和滞留性的物理特征相符。

西北风（wnd_dir_NW）和东南风（wnd_dir_SE）的 SHAP 值分别为 5.46×10^{-4} 和 3.91×10^{-4} ，位列第二和第三。北京地区不同风向对应不同的污染物输送路径：西北风通常带来清洁气团，有利于污染物扩散；东南风则可能将周边区域的污染物向城区

输送。SHAP 分析表明模型已捕捉到风向与 PM2.5 浓度之间的上述关联。

温度（temp）和露点（dew）的 SHAP 值分别为 3.37×10^{-4} 和 3.05×10^{-4} ，贡献相当。温度影响大气垂直对流强度，露点反映近地面水汽含量，两者分别从热力条件和湿度条件两个方面影响 PM2.5 的生成与扩散，模型对这两个特征赋予了相近的重要性。

静风（wnd_dir_cv）和东北风（wnd_dir_NE）的 SHAP 值分别为 2.93×10^{-4} 和 2.61×10^{-4} ，贡献略低于西北风和东南风。静风条件下大气水平运动弱，不利于污染物扩散；东北风在北京地区通常对应特定的天气系统过境影响。两者作为风向的补充类别，对模型预测起到了一定的辅助作用。

降雪（snow）、气压（press）、风速（wnd_spd）和降雨（rain）的 SHAP 值均低于 1×10^{-4} ，处于较低水平。其中降雨的 SHAP 值为 0.00。降雪和降雨在数据集中出现频次较低，累计小时数在大多数时刻为零，模型难以从中提取有效信号。风速量级的独立贡献可能已被风向特征所覆盖，气压变化在小时尺度上信息量有限，因而三者对 PM2.5 短时预测的贡献较小。

五. 结论

本文基于北京 PM2.5 空气质量数据集，开展了多变量 LSTM 模型的时序预测研究。通过对原始数据进行年份顺序划分、独热编码、归一化及滑动窗口构造等预处理，构建了适用于 LSTM 的监督学习样本。在超参数选择阶段，对时间窗口长度、LSTM 单元数和网络层数进行了对比实验，确定了最优配置。最终模型在测试集上取得了较好的预测性能，验证集与测试集指标接近，表明模型泛化能力良好，未出现明显过拟合。

通过 SHAP 可解释性分析，进一步考察了各输入特征对模型预测的贡献。结果显示，历史 PM2.5 浓度对预测的贡献最大，风向类别次之，温度与露点也具有一定的辅助作用，而降雪、降雨等稀疏特征贡献较小。上述特征重要性分布与大气污染物的物理演变规律基本吻合，从可解释性角度验证了多变量输入的必要性和模型内部决策的合理性。

综合来看，LSTM 网络结合多变量气象输入能够有效完成 PM2.5 浓度的小时级预测任务，较好地捕捉了污染序列的非线性变化趋势。模型在拟合整体规律方面表现出色，对突发极端峰值的预测仍有改进空间，未来可考虑引入更丰富的外部特征或采用

混合模型架构以进一步提升对短时剧烈变化的响应能力。

参考文献

- [1] Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735 – 1780.
- [2] Rupak, R. (2019). LSTM Datasets: Multivariate and Univariate [Dataset]. Kaggle.
<https://www.kaggle.com/datasets/rupakroy/lstm-datasets-multivariate-univariate>
- [3] Zhao, Z., Qin, J., Hu, A., Zhang, N., Xie, J., & Sun, Y. (2026). WaveNet-LSTM: A deep learning air quality prediction model based on both air pollutants and meteorological factors. *Information Sciences*, 730, 122894.
- [4] Bennis, M., Youssfi, M., Morabet, R. E., Alsubih, M., & Khan, R. A. (2026). Particulate matter (PM2.5 and PM10) prediction using fourier series decomposition in combination with LSTM and SVM. *Scientific Reports*, 16(1), 7665.
- [5] Zhang, S., Guo, B., Dong, A., He, J., Xu, Z., & Chen, S. X. (2017). Cautionary tales on air-quality improvement in Beijing. *Proceedings of the Royal Society A*, 473(2205), 20170457.