

基于混合分布 3D 数据的二分类方法比较研究

23375371 林孜

Linzi_15762331896@buaa.edu.cn

摘要

基于给定的非线性边界混合 3D 数据集分类问题开展研究。首先根据给定程序生成 3D 训练集与对应测试集，对原始数据完成可视化操作后，分别基于决策树、AdaBoost 集成决策树以及不同核函数的支持向量机构建分类模型。在模型构建过程中，对各类算法的超参数进行了系统调优，以确保各模型在公平条件下进行比较。通过准确率、精确率、召回率、F1 分数以及混淆矩阵等统一评价指标，对各模型在测试集上的分类性能进行全面评估，并结合数据集的几何结构与各算法的归纳偏置，分析不同模型在该非线性分类任务上表现差异的内在原因。

实验结果表明，采用非线性核函数的支持向量机能够有效拟合数据的弧形交错边界，整体表现最优。其中，多项式核 SVM 的测试集准确率达到 0.988，训练集与测试集性能完全一致，展现出最佳的泛化稳定性；RBF 核 SVM 的测试集准确率为 0.982，同样表现出极强的非线性拟合能力。AdaBoost 集成决策树模型次之，测试集准确率为 0.976，较单棵决策树的 0.940 有显著提升，说明 Boosting 机制通过逐轮关注难分类样本，能够有效增强模型的判别效果。然而，树模型在训练集与测试集之间存在不同程度的性能差距，表明其存在一定的过拟合倾向。相比之下，线性核 SVM 的测试集准确率仅为 0.686，且训练集与测试集表现均处于较低水平，说明其主要问题在于表达能力不足，无法有效适应当前数据的非线性结构。

综上，对于具有明显非线性几何特征的数据集，模型的分类性能优劣主要取决于其对非线性决策边界的表达方式。能够构造光滑连续非线性分界面的模型通常更具优势，而仅依赖线性边界或轴对齐局部划分的模型则相对处于劣势。

关键词：决策树；AdaBoost；支持向量机；核函数；非线性分类

一. 引言

分类任务是监督学习中的核心问题之一，其基本目标是根据带标记的训练样本，学习一个从输入特征空间到离散类别空间的映射函数，从而能够对未知类别的样本进行自动判别。形式化地，给定训练集 $D = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$ ，分类模型旨在学习假设函数 $h: \mathcal{X} \rightarrow \mathcal{Y}$ ，使得对未见样本的预测尽可能准确。

分类问题的重要性体现在多个方面。首先，它是许多现实应用的基础，如图像识别、文本分类、医疗诊断和信用评估等^[1,2]。分类问题的研究也推动了统计学习理论的发展，例如泛化误差分析、偏差-方差权衡等核心概念均源于此^[3]。此外，分类任务中存在的类别不平衡、标签噪声、特征高维等挑战，持续为算法设计提供创新空间^[4]。

本研究采用的数据集为程序生成的 3D 混合结构，在三维特征空间中，待分类的两类样本呈现出相互错位、局部交叠的弧形分布形态，同时叠加了高斯噪声干扰。从几何角度来看，两类样本之间不存在一个线性的分离超平面，其决策边界本质上是非线性的。这一特性使得该数据集能够有效区分不同分类模型对非线性模式的识别能力，因而适合作为算法比较实验的测试基准。

本文工作如下：基于给定数据集，在训练集上利用 Decision Trees、AdaBoost + DecisionTrees 与不同核函数的 SVM 分别建立分类函数，利用测试集在统一指标下评估测试其分类准确性，基于数据集结构与算法原理做出解释。

二. 算法原理

2.1 决策树方法 (Decision Trees)

决策树是一种非参数的监督学习方法，其核心思想是通过对特征空间的递归划分来实现分类。在构建过程中，算法在每个内部节点处选择一个最优特征及其对应的划分阈值，使得划分后子节点的样本纯度达到最大。常用的纯度度量指标包括信息熵、基尼系数和信息增益率等。这里我选用的是信息熵作为样本的纯度指标。

信息熵用于衡量样本集合的不确定性。设当前节点对应的样本集合为 D ，第 k 类样本所占比例为 p_k ，则该集合的信息熵定义为：

$$\text{Ent}(D) = - \sum_k p_k \log_2 p_k$$

熵值越大，表示样本的类别分布越混乱；熵值越小，则样本纯度越高。决策树通过选择使划分前后信息增益（即熵的下降幅度）最大的特征和阈值来构建节点。

划分过程持续进行，直至满足停止条件，如节点样本数低于阈值、纯度达到上限

或树深度达到预设值，最终在叶节点处赋予相应的类别标记。对于本研究所采用的 3D 混合数据，决策树能够通过多次轴对齐的局部划分，在一定程度上拟合非线性决策边界，分类呈现阶梯状边界特征。

从决策树方法可以发现，决策树适用于特征维度适中、数据中存在明显分段或矩形区域划分模式的问题。该算法对特征的量纲不敏感，无需进行标准化处理，且具有较强的可解释性。但当真实决策边界较为光滑或呈斜向、曲线形态时，单棵决策树往往需要极深的深度才能近似拟合，容易导致过拟合^[5]。

2.2 AdaBoost + Decision Trees

AdaBoost (Adaptive Boosting) 是一种集成学习方法，其核心思想是通过迭代方式训练多个弱分类器，并动态调整每一轮训练样本的权重分布，使得先前分类错误的样本在后续轮次中获得更高的关注度。最终，将所有弱分类器按照其分类性能进行加权组合，形成一个强分类器^[6]。

设训练集为 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_N, y_N)\}$ ，其中 $y_i \in \{-1, +1\}$ 。初始化样本权重分布为均匀分布：

$$w_1^{(i)} = \frac{1}{N}, i = 1, 2, \dots, N$$

在第 t 轮迭代中，根据当前权重分布 w_t 训练一个弱分类器 $h_t(\mathbf{x})$ ，并计算其在训练集上的加权分类误差：

$$\epsilon_t = \sum_{i=1}^N w_t^{(i)} \cdot \mathbf{I}(y_i \neq h_t(\mathbf{x}_i))$$

其中 $\mathbf{I}(\cdot)$ 为指示函数。然后，根据误差 ϵ_t 计算该弱分类器的投票权重：

$$\alpha_t = \frac{1}{2} \ln \left(\frac{1 - \epsilon_t}{\epsilon_t} \right)$$

误差越小， α_t 越大，表示该分类器在最终集成中拥有更高的表决权。

随后，更新样本权重分布，使下一轮模型更关注当前分类错误的样本：

$$w_{t+1}^{(i)} = \frac{w_t^{(i)} \exp(-\alpha_t y_i h_t(\mathbf{x}_i))}{Z_t}$$

其中 Z_t 为归一化因子，确保所有样本权重之和为 1。对于正确分类的样本 ($y_i h_t(\mathbf{x}_i) = 1$)，权重被缩小；对于错误分类的样本 ($y_i h_t(\mathbf{x}_i) = -1$)，权重被放大。

经过 T 轮迭代后，最终的强分类器为所有弱分类器的加权投票结果：

$$H(\mathbf{x}) = \text{sign} \left(\sum_{t=1}^T \alpha_t h_t(\mathbf{x}) \right)$$

本研究采用决策树桩（即深度为 1 的决策树）作为 AdaBoost 的基学习器。决策树桩仅依据单个特征及其阈值对样本进行分类，其分类能力较弱，属于典型的弱分类器。通过 AdaBoost 的迭代加权机制，多个决策树桩能够相互补充，逐渐聚焦于原始数据中难以分类的样本区域。

对于本研究所采用的 3D 混合数据，AdaBoost + 决策树能够通过多个弱分类器的加权集成，逐步逼近复杂的非线性决策边界。相较于单棵决策树所形成的阶梯状边界，集成后的决策边界更加平滑，分类精度通常更高。

从 AdaBoost + 决策树方法可以发现，该方法适用于弱分类器性能略优于随机猜测的问题，能够有效降低偏差并缓解过拟合。该方法对特征量纲不敏感，无需数据标准化处理。然而，当数据中存在较多噪声或异常值时，AdaBoost 可能过度聚焦于难分样本，导致模型泛化性能下降^[6]。此外，迭代训练的过程使其训练时间随弱分类器数量线性增长。

2.3 支持向量机 (SVM)

支持向量机是一种基于统计学习理论的监督分类方法，其核心思想是在特征空间中寻找一个最优分离超平面，使得两类样本之间的间隔最大化^[3]。对于线性可分的数据，该超平面能够将两类样本完全分开；对于线性不可分的数据，则通过引入核函数将样本映射到高维特征空间，在高维空间中寻找线性决策边界。

对于线性可分情形，设训练集为 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_N, y_N)\}$ ，其中 $y_i \in \{-1, +1\}$ 。分类超平面表示为：

$$f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$$

其中 $\mathbf{w}$ 为法向量， b 为偏置项。SVM 的目标是最大化两类样本到超平面的最小距离，即最大化间隔。

在实际应用中，数据往往存在噪声或线性不可分的情形。为此，引入松弛变量 ξ_i 允许部分样本违反间隔约束，形成软间隔 SVM。其优化问题为：

$$\begin{aligned} \min_{\mathbf{w}, b, \xi} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i \\ \text{s. t.} \quad & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, \xi_i \geq 0, i = 1, 2, \dots, N \end{aligned}$$

其中 C 为惩罚参数，控制间隔宽度与分类错误之间的权衡。

对于非线性分类问题，SVM 通过核函数 $K(\mathbf{x}, \mathbf{z})$ 将原始特征空间中的内积运算替换为高维空间中的隐式映射，从而在不显式计算高维特征的情况下实现线性可分。核

化后的决策函数为：

$$\hat{y} = \text{sign} \left(\sum_{i=1}^N \alpha_i y_i K(\mathbf{x}_i, \mathbf{x}) + b \right)$$

本研究选用三种不同的核函数进行比较分析。线性核函数形式简单，参数较少，适用于线性可分或近似线性可分的数据：

$$K_{\text{linear}}(\mathbf{x}, \mathbf{z}) = \mathbf{x}^T \mathbf{z}$$

径向基核函数（RBF）具有较强的局部拟合能力，能够处理复杂的非线性分布：

$$K_{\text{rbf}}(\mathbf{x}, \mathbf{z}) = \exp(\gamma \|\mathbf{x} - \mathbf{z}\|^2)$$

多项式核函数通过多项式映射构建决策边界，其表达能力受阶数控制：

$$K_{\text{poly}}(\mathbf{x}, \mathbf{z}) = (\gamma \mathbf{x}^T \mathbf{z} + c_0)^d$$

对于本研究所采用的 3D 混合数据，SVM 通过核函数将原始三维空间中的数据映射到更高维特征空间，从而在该空间中构造线性决策边界。不同核函数所诱导的决策边界形态各异，其分类性能与数据本身的几何分布密切相关。

从 SVM 方法可以发现，SVM 适用于中等规模、特征维度较高的分类问题，其对偶形式的优化保证了全局最优解的存在。核函数的选择是影响 SVM 性能的关键因素：线性核计算效率高但表达能力有限；RBF 核适应性强，能够拟合多种非线性结构；多项式核的决策边界受阶数影响较大。然而，SVM 对核参数和惩罚参数较为敏感，参数选择不当易导致欠拟合或过拟合^[3]。此外，随着训练样本规模增大，SVM 的计算复杂度显著上升。

2.4 评价指标

为了在后续模型比较中保持评价标准的一致性，本文选取准确率（Accuracy）、精确率（Precision）、召回率（Recall）和 F1-score 作为核心评估指标，并辅以混淆矩阵进行详细分析。

混淆矩阵是评估分类性能的基础工具，其结构如下表所示：

	预测为正类	预测为负类
真实为正类	TP	FN
真实为负类	FP	TN

其中，TP（True Positive）表示正确预测为正类的样本数，TN（True Negative）表示正确预测为负类的样本数，FP（False Positive）表示错误预测为正类的样本数，

FN (False Negative) 表示错误预测为负类的样本数。

基于混淆矩阵，各项指标定义如下：

准确率 (Accuracy) 衡量模型整体预测正确的比例：

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

精确率 (Precision) 衡量预测为正类的样本中实际为正类的比例：

$$\text{Precision} = \frac{TP}{TP + FP}$$

召回率 (Recall) 衡量实际为正类的样本中被正确预测出来的比例：

$$\text{Recall} = \frac{TP}{TP + FN}$$

F1-score 是精确率与召回率的调和平均值，综合反映模型的分类性能：

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

在上述指标中，准确率适用于类别平衡的场景；当各类别样本数量差异较大时，精确率、召回率与 F1-score 能够提供更为客观的评价依据。我们使用准确率判断模型的能力。

三. 原始数据分析

利用程序生成原始数据规模如下：训练集总规模为 1000，其中 C0 为 500，C1 为 500，测试集总规模为 500，其中 C0 为 250，C1 为 250。

对生成的原始数据做可视化分析，首先打印训练集与测试集在 3D 坐标系下的图，如下所示。




Figure1 训练集（左）与测试集（右）3D 点云

将三维点投影到 xy、xz、yz 平面，结果如下。




Figure2 训练集点投影图




Figure3 测试集点投影图

从图中可以看到，所生成的待分类点虽然具有明显的聚集特性，但是二者存在大量重叠与混合，并且二者无明显的线性边界，因此无法用线性分类器将二者分离。但是能够发现二者具有较为明显的非线性边界，因此用非线性分类器预计能收到较好的效果，下面将基于此数据分析开展后续实验。

四. 实验研究

4.1 实验超参数选择

三种实验方法具有多个超参数，下面将逐一介绍各个模型超参数选取方式。

4.1.1 Decision Tree

决策树中可调超参数为不纯度度量方法、最大树深、最小叶子节点数。经过测试，不纯度度量方法选择信息熵效果最佳。又对多最大树深进行联合测试，得到效果最好的为不限制最大树深的一组。最小叶子节点数经过测试准确率最高者为3。即最终超参数选择如下：不纯度度量方法为信息熵、不限制最大树深、最小叶子节点数为3。

相关测试结果如下表所示。

表 1 最小叶子节点数与测试准确率关系

最小叶子节点数	1	2	3	4	5
测试准确率	0.936	0.934	0.940	0.936	0.892

表 2 不纯度指标与测试准确率关系

不纯度指标	信息熵	基尼指数
测试准确率	0.940	0.936

表 3 最大树深与测试准确率关系

最大树深	2	3	4	5	8	10	15	20	不限
测试准确率	0.690	0.690	0.694	0.700	0.700	0.838	0.938	0.940	0.940

值得注意的是，从表组实验来看，如果最小叶子节点内含数最小与最大树深 unlimited，在该数据下并不会导致过拟合问题，测试集准确率与略微限制差别不大。

4.1.2 AdaBoost + Decision Trees

该部分有三个超参数：基学习器深度、弱分类器数量、学习率，同 4.1，固定两个参数，改变剩余一个参数，得到基学习器深度为 5、弱分类器 200、学习率 1.5。

相关测试结果如下。

表 4 基学习器深度与测试准确率关系

基学习器深度	1	2	3	4	5
测试准确率	0.722	0.944	0.968	0.974	0.974

表 5 弱分类器数量与测试准确率关系

弱分类器数量	25	50	100	150	200	300
测试准确率	0.702	0.720	0.954	0.968	0.968	0.968

表 6 学习率与测试准确率关系

学习率	0.01	0.05	0.1	0.5	1.0	1.5	2
测试准确率	0.702	0.720	0.954	0.968	0.968	0.968	0.926

4.1.3 SVM

在 SVM 中超参数有 C 惩罚系数、 γ 、 c_0 （多项式）、 d （多项式）。得到的最优结果为，Linear 核时 $C=0.1$ ，RBF 核是 $C=2$ ， $\gamma=1$ ，多项式核 $\gamma=0.5$ ， $c_0=1$ ， $d=4$ 。这一部分参数获取是固定单因素消融结果，即在给定某几个参数固定的情况下看其他超参数结果。这里不再展示测试结果，经过测试得到的最佳参数如上。

4.2 各模型性能比较

本文统计了所有模型的两类评估结果：一是在训练集上的表现，二是在测试集上的表现。每类结果都包含四个常用指标，即准确率、精确率、召回率和 F1 分数。这些

数据分别记录在下表中。由于测试集反映的是模型对未见过样本的预测能力，后续的分析主要围绕测试集展开。

表 7 训练集评价指标数据

测试模型	准确率	精确率	召回率	F1 score
Decision Tree	0.982	0.986	0.978	0.982
AdaBoost + Decision Trees	1	1	1	1
SVM (Linear Kernel)	0.678	0.682	0.666	0.674
SVM (RBF Kernel)	0.987	0.984	0.990	0.987
SVM (Polynomial Kernel)	0.988	0.986	0.990	0.987

表 8 测试集评价指标数据

测试模型	准确率	精确率	召回率	F1 score
Decision Tree	0.940	0.940	0.940	0.940
AdaBoost + Decision Trees	0.976	0.976	0.976	0.976
SVM (Linear Kernel)	0.686	0.687	0.684	0.685
SVM (RBF Kernel)	0.982	0.984	0.980	0.982
SVM (Polynomial Kernel)	0.988	0.984	0.992	0.988

利用测试集参数绘制结果图如下。



Figure4 结果柱状图

综合表测试集与训练集结果来看，各模型在该 3D 数据集上的泛化特征存在明显差异。SVM（Polynomial Kernel）的训练集准确率为 0.988，测试集准确率同样为

0.988，两者完全一致，说明该模型不仅拟合能力强，而且具有良好的泛化稳定性。SVM（RBF Kernel）的训练集准确率为 0.987，测试集准确率为 0.982，下降幅度仅为 0.005，同样表现出高度一致的训练与测试性能，说明其决策边界与数据结构具有较高的匹配度。相比之下，AdaBoost + Decision Trees 的训练集准确率达到完美的 1.000，但测试集准确率下降至 0.976，降幅为 0.024；Decision Tree 的训练集准确率为 0.982，测试集准确率为 0.940，降幅为 0.042。这两个树模型在训练集上的表现均优于测试集，说明它们虽然具有较强的拟合能力，但在当前任务上仍存在一定程度的过拟合倾向，其中单棵决策树的过拟合程度更为明显。另一方面，SVM（Linear Kernel）在训练集和测试集上的准确率分别仅为 0.678 和 0.686，两者均处于较低水平且差距很小，这表明其主要问题并非过拟合，而是模型表达能力不足，无法有效适应当前数据的非线性结构。

由测试集结果可知，不同模型在该 3D 数据集上的分类性能差异较为显著。采用非线性核函数的支持向量机整体表现最佳，其中 SVM（Polynomial Kernel）在测试集上取得最高的综合性能，准确率达到 0.988，精确率、召回率和 F1 分数分别为 0.984、0.992 和 0.988；SVM（RBF Kernel）的测试集准确率为 0.982，精确率、召回率和 F1 分数分别为 0.984、0.980 和 0.982，与多项式核模型非常接近，同样表现出极强的分类能力。AdaBoost + Decision Trees 的测试集准确率为 0.976，虽略低于两种高性能非线性核 SVM，但仍明显优于单棵 Decision Tree 的 0.940。而 SVM（Linear Kernel）的测试集准确率仅为 0.686，显著低于其他模型，说明线性模型对于当前数据的非线性结构适应性较差。

4.3 混淆矩阵分析

绘制数据的混淆矩阵，如下图所示。




Figure5 混淆矩阵图

通过各模型在测试集上的混淆矩阵可以进一步分析其分类错误的具体分布。从推算结果来看，SVM（Polynomial Kernel）的错误总数最少，共计 6 个误判样本，其中将 C1 误判为 C0 的有 2 个，将 C0 误判为 C1 的有 4 个。SVM（RBF Kernel）的错误总数为 9 个，C1 误判为 C0 的有 5 个，C0 误判为 C1 的有 4 个。这两个模型的错误数量相近且均处于较低水平，说明非线性核 SVM 能够较好地地区分两类样本。AdaBoost + Decision Trees 的错误总数为 12 个，两类错误各为 6 个，分布完全对称。Decision Tree 的错误总数为 30 个，两类错误各为 15 个，同样呈现对称分布。SVM（Linear Kernel）的错误总数最多，达到 157 个，其中将 C1 误判为 C0 的有 79 个，将 C0 误判为 C1 的有 78 个，两类错误数量基本持平。

观察各模型在两类上的错误分布可以发现，所有五个模型的 FP 与 FN 数值均较为接近，没有出现某一类错误显著多于另一类的情况。这说明各模型在对 C0 和 C1 两类样本的识别上保持了较好的平衡性，未表现出明显的类别偏好。即便是性能最差的线性核 SVM，其两类错误数量也基本相当。这一现象与该数据集的构造方式有关：3D 数据在生成时对两类样本采用了对称的构造策略，使得两类样本在空间中的分布形态和复杂度相近，因此模型不会倾向于某一类。

4.4 该数据算法表现差异原因

结合前文数据可视化结果与各模型的测试集准确率，可以进一步分析不同模型性

能差异的根本原因。由第三节的 3D 点云图及二维投影图可知，该数据集在三维特征空间中呈现明显的交错与弯曲结构，两类样本之间不存在线性的分离超平面，其决策边界本质上是非线性的。因此，模型在该任务上的表现优劣，关键在于其是否能够学习到与真实类别边界相匹配的非线性决策函数。

SVM (Linear Kernel) 表现最差，测试集准确率仅为 0.686。其根本原因在于该模型只能学习线性超平面，而当前数据的类别边界具有明显的弯曲特征，线性模型的表达能力存在本质限制。从训练集与测试集准确率接近且均处于较低水平这一现象可以判断，该模型的主要问题并非过拟合，而是从模型层面就无法有效拟合数据的基本结构。

Decision Tree 的测试集准确率达到 0.940，显著优于线性核 SVM，说明树模型具备一定的非线性表达能力。然而，决策树的空间划分方式是轴对齐的递归切分，其生成的决策边界呈现阶梯状。面对当前数据中具有连续弯曲结构的分界面，单棵决策树只能通过分段方式近似拟合，因此在局部区域容易产生误分类。同时，该模型训练集准确率为 0.982、测试集为 0.940，存在明显的性能下降，表明其存在一定程度的过拟合倾向。

AdaBoost + Decision Trees 通过集成多个决策树桩，显著提升了模型对复杂边界的刻画能力。其测试集准确率达到 0.976，较单棵决策树提升了 3.6 个百分点，混淆矩阵中的误判数量也从 30 个减少至 12 个。这表明 Boosting 机制通过逐轮关注难分类样本并调整权重分布，能够有效增强模型的判别效果。然而，该模型在训练集上达到了完美的 1.000 准确率，测试集与之存在 0.024 的差距，说明集成学习虽然改善了拟合能力，但仍未完全克服过拟合问题。

SVM (Polynomial Kernel) 与 SVM (RBF Kernel) 在本实验中表现最佳，测试集准确率分别达到 0.988 和 0.982。这两个模型能够取得优异性能的原因在于，它们通过核技巧将原始三维空间中的数据隐式映射到高维特征空间，从而在该空间中构造出线性决策边界，对应回原始空间则形成光滑的非线性分界面。这种决策边界形态与当前数据的弧形交错结构高度匹配。其中，多项式核在本次实验中取得最高综合性能，且训练集与测试集准确率完全一致（均为 0.988），说明该模型在拟合能力与泛化稳定性之间取得了最佳平衡。RBF 核的表现与之非常接近，同样展现出极强的非线性建模能力。

综上所述，对于具有显著非线性几何结构的数据，模型性能的优劣主要取决于其

对非线性边界的表达方式。能够构造光滑、连续非线性分界面的模型（如非线性核 SVM）表现最佳；通过集成方式增强局部拟合能力的模型（如 AdaBoost）次之；仅依赖轴对齐划分的模型（如单棵决策树）再次之；而只能学习线性边界的模型（如线性核 SVM）则因表达能力不足而难以胜任该任务。

五. 结论

本文在三维数据集上对五种分类模型进行了实验比较。从测试集准确率来看，非线性核 SVM（多项式核与 RBF 核）取得了最优结果，分别达到 0.988 和 0.982，且训练与测试性能高度一致，泛化稳定性良好。AdaBoost 集成决策树的测试准确率为 0.976，较单棵决策树（0.940）有明显提升，但两者均存在不同程度的过拟合现象。线性核 SVM 的准确率仅为 0.686，表明其无法应对数据的非线性结构。综合以上结果，当数据呈现弯曲交错的空间分布时，模型能否构造与真实边界相匹配的非线性决策面，是决定分类效果的关键因素。

参考文献

- [1] Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- [2] Kotsiantis, S. B. (2007). Supervised machine learning: A review of classification techniques. *Informatica*, 31(3), 249 – 268.
- [3] Vapnik, V. N. (1998). *Statistical Learning Theory*. Wiley.
- [4] He, H., & Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9), 1263 – 1284.
- [5] Loh, W. Y. (2011). Classification and regression trees. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, 1(1), 14 – 23.
- [6] Freund, Y., & Schapire, R. E. (1997). A decision-theoretic generalization of on-line learning and an application to boosting. *Journal of Computer and System Sciences*, 55(1), 119 – 139.