

Transformer 复现与 KV 消融实验

23375371 林孜

Linzi_15762331896@buaa.edu.cn

摘要

本文基于 Multi30K 英-德平行句对数据集，开展了 Transformer 模型的机器翻译复现与核心组件消融研究。数据集包含约 3 万句对，按标准划分训练集（约 2.9 万）、验证集和测试集（各约 1000）。预处理阶段采用空格分词、构建词表并截断至最大长度。模型方面，从零实现标准 Transformer（编码器/解码器各 3 层，模型维度 256，注意力头数 8，前馈网络维度 1024，dropout 0.1），在 Ubuntu 服务器（7×RTX3090）上采用 Adam 优化器与 Noam 学习率调度训练 20 个 epoch。主复现实验结果表明：测试集 BLEU 达 24.66，验证集最佳 BLEU 为 26.05，训练损失从 5.77 降至 0.81，验证损失在第 9 代最低后略有回升但 BLEU 持续改善，成功验证了 Transformer 在小规模数据上的收敛行为。在此基础上，设计 KV 消融实验——将键与值的投影矩阵合并（共享 K-V），以探究 Q、K、V 三者分离的必要性。消融结果显示，测试 BLEU 降至 22.34，测试困惑度从 9.53 升至 9.87，性能显著下降，证明独立的值投影对模型表达能力至关重要，注意力权重计算与值变换的解耦是 Transformer 有效性的关键。综合翻译性能与消融对比，本文不仅复现了 Transformer 的核心训练行为，而且从实证角度验证了多头注意力中 Q、K、V 分离的必要性，为后续注意力机制的改进提供了经验依据。

关键词：Transformer；机器翻译；多头注意力；消融实验；QKV 分离

一. 引言

在深度学习主导自然语言处理研究之前，统计机器翻译方法长期面临着特征工程复杂、长距离依赖难以建模以及语料稀疏性等诸多挑战^[1]。随着神经网络技术的复兴，基于循环神经网络（RNN）的编码器-解码器架构迅速成为序列转录任务的主流框架^[2]。这类方法通过引入注意力机制，让解码器在生成每个目标词时能够动态地关注源序列中的相关位置，从而显著缓解了长距离依赖问题^[2]。然而，RNN 的本质特性决定了其计算必须沿着时间步依次进行，即当前位置的隐状态必须等待前一个位置计算完毕才能开始。这种固有的时序依赖严重限制了训练阶段的并行化能力，尤其是在处理长序列时，由于显存限制导致批次大小被迫减小，进一步拉长了模型迭代周期^[3]。尽管后续研究提出了 LSTM、门控循环单元以及多种因子分解技巧来缓解梯度消失和提升计算效率，但循环网络顺序计算的根本约束始终未能被突破^[3]。

正是在这一背景下，Vaswani 等人提出了完全基于注意力机制的 Transformer 模型，彻底摒弃了循环与卷积结构^[3]。这一设计的最大优势在于打破了时序依赖对并行计算的束缚：自注意力层可以在序列的所有位置上同时计算输出，使得模型能够在 GPU 等并行硬件上实现高效的批量训练。实验结果表明，在 WMT 2014 英-德翻译任务上，Transformer 的大模型版本达到了 28.4 BLEU，超过了当时包括集成模型在内的所有已有最佳结果 2 个点以上；在英-法翻译任务上，该模型仅用 3.5 天在 8 块 P100 GPU 上训练便取得了 41.8 BLEU 的单模型最佳成绩，而此前的最佳模型训练成本远超这一规模^[3]。这些成果不仅推动了机器翻译领域的技术边界，也为后续 BERT、GPT 等模型奠定了重要的架构基础^{[4][5]}。

Transformer 之所以能够实现上述突破，主要得益于其核心组件的精心设计^[3]。Transformer 的自注意力机制直接计算任意两个位置之间的相关性权重，使得远距离信息传递的路径长度压缩至常数级别，相比之下 RNN 需要 $O(n)$ 步而 CNN 需要 $O(\log_k n)$ 步才能让两端位置相互影响^{[3][6]}。并且其有多头注意力机制，将查询、键、值矩阵分别进行多次线性投影后在降维空间上并行执行注意力计算，再将各头的结果拼接起来，这使得模型能够从不同的表示子空间中联合提取信息，增强了表达的丰富性^[3]。Transformer 也在每个注意力层和前馈层周围都采用了残差连接并辅以层归一化，这一设计缓解了深层网络训练时的梯度消失问题，使得堆叠 6 层甚至更多层的编码器和解码器成为可能^{[1][3]}。虽然模型本身不具备感知序列顺序的能力，但作者引入了基于正弦

与余弦函数的位置编码，将其与词嵌入相加后输入网络，从而使模型能够利用词的位置信息进行推理^[3]。这些机制的协同作用构成了 Transformer 强大的序列建模能力。

本实验旨在复现 Transformer 基础模型，并在可控环境下验证其核心组件 Q、V、K 的必要性。首先，基于 Multi30K 英-德平行句对数据集和 PyTorch 框架，完整实现了原始论文中描述的模型架构与训练流程，确保核心组件正确实现并能够观察到合理的收敛行为^[3]。在此基础上，本实验重点关注注意力机制中 Q、K、V 三者分离的必要性，设置了两组对照实验：标准独立 Q/K/V 投影与共享 K-V 投影（即合并 K 与 V）的线性变换，以来系统评估独立值投影对翻译性能的影响。评价指标采用机器翻译任务中广泛使用的 BLEU 值，并在验证集上同时记录困惑度和交叉熵损失以监控训练过程^[8]。优化器采用 Adam 算法并遵循原文中的学习率预热与衰减策略^{[3][9]}。通过上述实验设计，本报告期望量化 Q、K、V 分离对模型表达能力的实际贡献，并通过损失曲线与 BLEU 对比揭示其内在机理，从而加深对 Transformer 注意力机制工作原理的理解，也为未来注意力机制的改进方向提供经验依据。

二. 算法原理

2.1 缩放点积注意力

注意力机制的核心思想是让模型在处理一个位置时能够有选择地关注输入序列中的其他位置。Transformer 提出了一种名为“缩放点积注意力”（Scaled Dot-Product Attention）的简单而高效的实现方式^[3]，其结构如下图所示。

Scaled Dot-Product Attention




图 1 缩放点积注意力结构

给定一个查询（Query）和一组键-值对（Key-Value pairs），注意力函数的输出是值的加权和，其中权重由查询与对应键的兼容性决定。具体而言，将查询与所有键计算点积，每个点积除以缩放因子 $\sqrt{d_k}$ ，然后通过 Softmax 函数转化为概率分布，最后用该分布对值进行加权求和。整个过程可表示为：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

其中 Q 、 K 、 V 分别代表查询矩阵、键矩阵和值矩阵， d_k 为键向量的维度。除以 $\sqrt{d_k}$ 的缩放操作是为了防止当 d_k 较大时点积值落入 Softmax 函数的饱和区域，从而避免梯度消失问题^[3]。

2.2 多头注意力

单个注意力机制可能只能捕捉到序列中某种特定类型的关系，而不同的位置关系、语法结构和语义关联往往需要在不同的表示子空间中进行建模。为此，Transformer 引入了多头注意力（Multi-Head Attention）机制^[3]，其结构如下图。




图 2 多头注意力结构

多头注意力的做法是：将原始的 Q 、 K 、 V 分别通过 h 组不同的线性投影矩阵映射到多个低维空间，在每个投影后的低维空间上独立执行缩放点积注意力，得到 h 个输出向量，将它们拼接后再进行一次线性变换，得到最终的输出。其数学表达为：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O$$

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$$

其中 W_i^Q 、 W_i^K 、 W_i^V 和 W^O 均为可学习的线性投影矩阵。原始论文中采用 $h = 8$ 个并行注意力头，每个头的维度为 $d_k = d_v = d_{\text{model}}/h = 64$ 。这种设计允许模型从不同的子空间中关注来自不同位置的信息，多头并行计算也充分适配 GPU 硬件架构^[3]。

2.3 位置编码

由于 Transformer 完全摒弃了循环和卷积结构，模型本身不具备感知序列顺序的能力。然而在自然语言处理中，词的先后顺序往往携带了至关重要的语义信息。因此，需要在输入嵌入中加入位置信息，这一过程称为位置编码^[3]。

原始 Transformer 使用正弦和余弦函数构造位置编码，具体形式为：

$$PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right)$$

$$PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right)$$

其中 pos 表示词在序列中的绝对位置， i 表示维度索引。这种设计的优势在于：对于任意固定偏移量 k ， PE_{pos+k} 可以表示为 PE_{pos} 的线性函数，从而使模型更容易学习相对位置关系^[3]。编码后将位置向量与词嵌入向量逐元素相加，作为编码器和解码器栈的底层输入。

2.4 编码器与解码器架构

Transformer 整体采用编码器-解码器架构^[3]，其总体结构如图 3 所示。编码器由 $N = 6$ 个完全相同的层堆叠而成，每个层包含两个子层：第一个是多头自注意力子层，用于让每个位置关注同一输入序列中的所有其他位置；第二个是前馈网络子层，对每个位置的表示进行独立的非线性变换。每个子层周围都采用了残差连接，其后进行层归一化，即每个子层的输出为 $\text{LayerNorm}(x + \text{Sublayer}(x))$ 。所有子层和嵌入层均产生维度 $d_{\text{model}} = 512$ 的输出，以便于残差连接。

解码器同样由 $N = 6$ 个相同层堆叠而成，但在编码器两个子层的基础上额外插入第三个子层——编码器-解码器注意力子层。该子层的查询来自解码器前一层的输出，而键和值来自编码器的输出，使得解码器的每个位置都能关注输入序列的所有位置。解码器的自注意力子层经过特殊修改，通过掩码操作禁止当前位置关注后续位置，从而保持自回归特性，即生成第 i 个位置的输出时只能依赖于 i 之前的已知输出^[3]。

Transformer 整体架构如下图所示。左半部分为编码器栈，包含多头自注意力和前馈网络，带有残差连接和层归一化；右半部分为解码器栈，除自注意力和前馈网络外，还包含编码器-解码器注意力子层，且自注意力子层带有掩码。




图 3 Transformer 模型架构

2.5 前馈网络与残差连接

除了注意力子层外，编码器和解码器的每一层都包含一个全连接的前馈网络（Feed-Forward Network, FFN），该网络对每个位置独立且相同地进行处理。前馈网络包含两次线性变换，中间采用 ReLU 激活函数：

$$\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

同一层内不同位置共享相同的参数，但不同层之间的参数不同。从卷积的角度理解，这等价于两个核大小为 1 的一维卷积。原文设置输入输出维度 $d_{\text{model}} = 512$ ，隐藏层维度 $d_{\text{ff}} = 2048^{[3]}$ 。

残差连接（Residual Connection）是 Transformer 能够成功训练深层模型的关键因素之一，其概念最初由 He 等人提出用于图像识别^[1]。其核心思想是将子层的输入直接加到子层的输出上，使梯度可以绕过子层的非线性变换直接反向传播。层归一化

(Layer Normalization) 则在残差之后对特征维度进行归一化，稳定训练过程并加速收敛^[1]。这两种机制的配合使得堆叠 6 层甚至更多层的 Transformer 网络能够稳定训练，

2.6 评价指标

为了在后续的模型评估中保持评价标准的一致性，并能够与原始论文的结果进行有效对比，本文选取 BLEU、困惑度以及交叉熵损失作为核心评价指标^{[3][8]}。

设测试样本数为 N ，第 i 个样本的真实输出序列为 $\mathbf{y}_i$ ，模型生成的译文序列为 $\hat{\mathbf{y}}_i$ ，各项指标定义如下。

BLEU (Bilingual Evaluation Understudy) 通过计算候选译文与一个或多个参考译文的 n -gram 匹配程度来评估翻译质量^[8]。其计算公式为：

$$\text{BLEU} = \text{BP} \cdot \exp \left(\sum_{n=1}^N w_n \log p_n \right)$$

其中 p_n 为 n -gram 的精确率， w_n 为权重 (通常取 $w_n = 1/N$)，BP 为长度惩罚因子，用于防止模型倾向于生成过短的译文。当候选译文长度 c 大于参考译文长度 r 时 $\text{BP} = 1$ ，否则 $\text{BP} = e^{(1-r/c)}$ 。BLEU 值范围在 0 到 100 之间，值越高表示翻译质量越好。

困惑度 (PPL) 衡量模型对验证集的预测置信度，定义为交叉熵损失的指数形式：

$$\text{PPL} = \exp \left(-\frac{1}{N} \sum_{i=1}^N \log p(\mathbf{y}_i | \mathbf{x}_i) \right)$$

其中 $\mathbf{x}_i$ 为源语言输入序列， $p(\mathbf{y}_i | \mathbf{x}_i)$ 为模型生成目标序列的概率。困惑度越低，表明模型对词序列的预测越确定。

交叉熵损失 (Cross-Entropy Loss) 是模型训练过程中直接优化的目标函数，在每个时间步上计算预测词分布与真实词分布之间的差异。对于单个样本，其形式为：

$$\mathcal{L}_{\text{CE}} = -\frac{1}{T} \sum_{t=1}^T \log p(y_t | y_{<t}, \mathbf{x})$$

其中 T 为目标序列长度， y_t 为第 t 个位置的真实词， $p(y_t | y_{<t}, \mathbf{x})$ 为模型预测该词的概率。本实验将在训练过程中记录每个 epoch 的训练损失与验证损失，用以判断模型收敛程度以及是否存在过拟合现象。

综合使用上述三项指标，可以从不同层面评估模型的翻译性能：BLEU 直接反映译文质量，困惑度衡量模型的整体不确定度，交叉熵损失则用于监控训练过程。

三. 原始数据与训练设备

3.1 原始数据信息

由于设备性能以及训练快速性等因素考量，原始数据集采用从 Hugging Face 下载的规模较小的 Multi30k 数据集。Multi30K 数据集基于 Flickr30K 图像数据集构建，每张图片配有 5 句英文描述以及对应的德语译文，我们这里只选择翻译对作为我们的训练样本。数据集规模约为 3 万句对，我们采用训练集约 29000 句对、测试集与验证集各 1000 句对左右的数据划分形式。

3.2 训练设备信息

代码完成后我尝试在自己电脑上跑，但是本人电脑仅有 CPU，因此训练相当慢，因此我把训练环境换到服务器上。服务器是 Ubuntu 系统多卡（7*RTX3090）服务器，训练速度从原始电脑的约 4000s 迭代一轮提升到了 29s 迭代一轮，提升 100 多倍。

四. 复现过程

4.1 数据预处理

本文采用 Multi30K 数据集作为实验数据，该数据集包含约 29,000 个训练句对、1,000 个验证句对和 1,000 个测试句对。对于每个句子，采用基于空格的分词方式，并将所有字母转换为小写。基于训练集构建源语言（英语）和目标语言（德语）的词表，词表大小限制为 10,000 个词，同时过滤掉出现频率低于 2 次的低频词。词表中包含四个特殊标记：<pad>（填充）、<bos>（起始）、<eos>（结束）、<unk>（未登录词）。编码时，每个句子被转换为 [<bos> 词 ID 序列, <eos>] 的形式，并截断至最大长度 80 个 token。数据加载时采用动态填充策略，将同一批次内的序列填充至相同长度。

4.2 模型实现

本文基于 PyTorch 框架从零实现完整的 Transformer 模型。整体采用编码器-解码器架构，编码器和解码器各堆叠 $N = 3$ 层。模型前向传播时，源序列经嵌入层和位置编码后送入编码器栈，得到记忆表示；目标序列（起始符后）经嵌入层和位置编码后送入解码器栈，同时接收编码器的记忆表示；解码器输出经线性投影得到目标词表的 logits。

位置编码模块按原文正弦-余弦公式生成固定编码矩阵，维度为 $\text{max_len} \times d_{\text{model}}$ ，其中 $\text{max_len} = 5000$ ， $d_{\text{model}} = 256$ 。编码值在训练前预先计算并注册为缓冲区（不参与梯度更新），前向传播时直接与词嵌入相加。词嵌入在相加前乘以

$$\sqrt{d_{\text{model}}}。$$

缩放点积注意力函数实现为： $\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$ 。中通过矩阵乘法计算注意力分数，除以 $\sqrt{d_k}$ ($d_k = d_{\text{model}}/h = 32$) 进行缩放，需要掩码时将非法位置设为 $-\infty$ ，然后经 Softmax 与值矩阵相乘。多头注意力模块将 Q, K, V 分别通过 $h = 8$ 组线性投影映射到低维空间，并行执行缩放点积注意力后拼接结果，再经输出投影得到最终输出。所有线性投影层均使用 PyTorch 的 nn. Linear 实现，无偏置项。

前馈网络实现为两个线性层中间插入 ReLU 激活和 Dropout: $\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$ ，维度变化为 $256 \rightarrow 1024 \rightarrow 256$ 。每个编码器层和解码器层中的子层（自注意力、交叉注意力、前馈网络）后均采用残差连接与层归一化，顺序为“子层 $\rightarrow$ Dropout $\rightarrow$ 残差加法 $\rightarrow$ 层归一化”。层归一化使用 nn. LayerNorm, ϵ 采用默认值 10^{-5} 。解码器的自注意力子层中应用了三角掩码，以保证自回归特性。

4.3 训练配置

超参数设置如下表所示。

表 1 Transformer 模型超参数

超参数	取值
d_{model}	256
d_{ff}	1024
N	3
h	8
$p(\text{dropout})$	0.1
batch size	64
最大序列长度	80
学习率预热步数	4000
epochs	20
优化器	Adam
学习率调度	Noam 策略

损失函数	交叉熵损失
梯度裁剪阈值	1.0

4.4 训练流程

每个 epoch 中，按批次加载数据，将源序列和目标序列移至 GPU。目标序列拆分为解码器输入（去掉最后一个位置）和损失目标（去掉第一个位置）。模型前向传播得到 logits 后计算损失，执行反向传播、梯度裁剪和优化器更新，学习率在每个训练步动态调整。每个 epoch 结束后在验证集上计算交叉熵损失、困惑度和 BLEU，并保存验证集 BLEU 最高的模型检查点。解码采用贪心搜索：以<bos>为起始逐词生成，每步选取概率最大的词，直至生成<eos>或达到最大长度。

4.5 评估方法

本文采用三项指标评估模型性能。交叉熵损失记录每个 epoch 的训练和验证损失，用于监控收敛与过拟合。困惑度由 $PPL = \exp(CE)$ 计算。BLEU 分数在验证集和测试集上采用 4-gram 计算。测试时加载最佳检查点，在测试集上计算最终 BLEU 作为主要评价指标。

五. KV 消融实验设计

5.1 实验目的

为了探究 Transformer 中 Q、K、V 三者分离的必要性，本实验设计了一组对照实验，对比标准注意力机制与 K、V 共享投影的变体在机器翻译任务上的表现。实验的核心假设是：独立的 K 和 V 投影能够为模型提供更强的表达能力，因为注意力权重计算（基于 Q 与 K 的兼容性）和值的变换（基于 V 投影）可以解耦，而共享 K 与 V 会迫使模型使用相同的表示同时扮演两个角色，可能限制模型的性能。

5.2 实验过程

在标准 Transformer 模型的基础上，修改多头注意力模块，将键和值的线性投影合并为同一个线性层，即 $K = W_{kv}X$, $V = W_{kv}X$ ，而查询仍使用独立的投影 $Q = W_qX$ 。此时注意力计算变为 $\text{Attention}(Q, K) = \text{softmax}(QK^T/\sqrt{d_k})K$ ，不再有独立的 V 矩阵。两组实验除注意力模块外，所有其他超参数、数据预处理、训练策略和随机种子均保持一致。实验均在相同的 Multi30K 英-德数据集上训练 20 个 epoch，每个 epoch 结束后在验证集上计算交叉熵损失、困惑度和 BLEU 分数，并保存验证 BLEU 最高的模型检查点，最后在测试集上评估最佳模型的 BLEU 分数。通过对比标准模型与共享 K-V

模型在测试集上的 BLEU 差异，即可定量评估 Q、K、V 分离对翻译性能的实际贡献。

六. 实验结果与分析

6.1 主复现实验结果与分析

复现原文 transformer 在 Multi30K 英-德翻译任务上训练 20 个 epoch，其训练和验证过程中的交叉熵损失、困惑度及验证 BLEU 变化如下图所示。




图 4 原版 transformer 的 loss 与 BLEU 曲线

从训练动态来看，训练交叉熵从第 1 代的 5.770 持续下降至第 20 代的 0.807，训练困惑度从 320.49 降至 2.24，表明模型在训练集上拟合充分，没有出现欠拟合现象。验证交叉熵在第 9 代达到最低值 2.057，之后缓慢上升至第 20 代的 2.229，验证困惑度也相应地从 7.82 升至 9.29，说明第 9 代后模型开始出现过拟合。模型过度学习了训练集中的特定模式，导致在验证集上的泛化能力下降。这种过拟合可能是由于数据集较小且模型比较复杂导致的。

但是验证 BLEU 并未随验证损失上升而下降。第 9 代验证损失最低时 BLEU 为 25.23，第 20 代验证损失虽升高至 2.229，但 BLEU 反而达到峰值 26.05。这种“损失升高而 BLEU 改善”的现象在机器翻译中并不罕见，因为交叉熵损失关注每个 token 的预测概率，而 BLEU 衡量的是整体译文质量，两者优化目标不完全一致。后期模型可能在某些 token 上预测置信度略有下降，但整体词序和短语选择更贴近参考译文，从而获得更高的 BLEU。

表 2 关键 epoch 的输出指标

Epoch	Train CE	Train PPL	Val CE	Val PPL	Val BLEU
-------	----------	-----------	--------	---------	----------

1	5.770	320.49	4.026	56.03	8.46
9	1.637	5.14	2.057	7.82	25.23
20	0.807	2.24	2.229	9.29	26.05

最终在测试集上，最佳模型（取为第 20 代）取得测试交叉熵 2.2545、测试困惑度 9.53、测试 BLEU 24.66。验证集最佳 BLEU 为 26.05，测试集 BLEU 略低，表明模型对验证集存在一定过拟合，但差距在可接受范围内。

与原始论文^[3]的 WMT 2014 英-德任务相比，本文使用的模型规模（3 层，256 维）和数据集（Multi30K，约 3 万句对）均远小于原文（6 层，512 维，450 万句对），因此 BLEU 值较低是合理的。能看到本文的训练曲线与原文描述一致：学习率预热阶段收敛迅速，验证损失后期趋于平缓或略升，BLEU 持续改善。本实验成功复现了 Transformer 的核心训练行为，在有限资源下仍能获得较优结果。

6.2 KV 消融实验结果与分析

KV 消融后 transformer 的 loss 与 BLEU 曲线如下所示。前后两次实验的 BLEU 也放在下面。能够看到 Loss（CE）虽然与原来差不多（略差），但是 Validation BLEU 比原本低较多。




图 5 KV 消融后 transformer 的 loss 与 BLEU 曲线

二者结果放在一处对比，如下所示。




图 6 KV 消融前后 transformer 的结果对比

从测试集输出中能看到，最终模型的交叉熵为 2.3449，测试困惑度 9.87，测试 BLEU 为 22.34。和原始数据对比如下表所示。

表 3 原始数据与 KV 消融后各项指标

	Test CE	Test PPL	Test BLEU
共享模型	2.2545	9.53	24.66
共享 KV	2.3449	9.87	22.34

这一结果与标准 Transformer 相比，性能出现了明显下降。标准模型的测试 BLEU 为 24.66，测试交叉熵为 2.2545，测试困惑度为 9.53；而共享 K-V 模型的测试 BLEU 降至 22.34，测试交叉熵升至 2.3449，测试困惑度升至 9.87。

该消融结果表明，将键与值的投影矩阵合并（即使得 $K = V$ ）对 Transformer 的翻译质量产生了显著的负面影响。分析其原因主要有两点：第一，独立的 V 投影允许模型在计算注意力权重，即 Q 与 K 之后，对值向量进行独立的线性变换，从而能够根据不同的上下文动态调整“被加权求和的信息内容”。当 K 与 V 共享时，值向量被强制等同于键向量，模型失去了这种灵活调整的能力，只能将注意力权重直接作用于原始的键表示上，限制了输出表达的丰富性。第二，共享 K-V 投影减少了模型的参数量，即每个注意力头减少了一个 $d_{\text{model}} \times d_k$ 的矩阵，虽然这降低了过拟合风险，但在当前任务中，参数量的减少带来的表达能力下降远超正则化收益，导致整体性能降低。

并且我们能看到，共享 K-V 模型的损失与标准模型差距较小，而 BLEU 差距较大。这再次验证了交叉熵损失与 BLEU 并非完全正相关：共享 K-V 模型可能在单个 token 的预测概率上仍保持较好水平，但在生成完整序列时，词序、短语搭配等整体结构质量明显下降。综上，实验证实了 Q、K、V 三者分离的必要性，独立的值投影矩阵对于 Transformer 达到良好翻译性能至关重要。

七. 结论

本文基于 Multi30K 英-德平行句对数据集，开展了 Transformer 模型的机器翻译复现与消融研究。首先，按照原始论文的架构，从零实现了 3 层、256 维的 Transformer 模型，并在 20 个训练周期内获得了测试 BLEU 24.66、困惑度 9.53 的结果，验证了模型在小规模数据集上的有效收敛。在此基础上，通过修改多头注意力模块，设计了共享 K-V 投影的消融实验，以探究 Q、K、V 三者分离的必要性。

消融实验结果表明，将键与值的投影矩阵合并（即 $K = V$ ）会导致翻译质量显著下降：测试 BLEU 从 24.66 降至 22.34，测试困惑度从 9.53 升至 9.87。这一现象说明，独立的值投影矩阵对于 Transformer 模型至关重要。它允许注意力权重与值变换解耦，使模型能够根据不同的上下文动态调整被加权求和的信息内容；而共享 K-V 则强制值向量等同于键向量，限制了输出表达的丰富性。同时，交叉熵损失与 BLEU 并非完全正相关：共享 K-V 模型的损失仅略有升高，但 BLEU 下降明显，反映出该变体在整体序列生成上的能力损失远大于单个 token 预测概率的损失。

综合来看，本文成功复现了 Transformer 的核心训练行为，并通过 KV 消融实验从可解释性角度验证了多头注意力中 Q、K、V 分离的必要性。模型在拟合翻译规律方面表现出色，但对小规模数据集的过拟合现象依然存在，未来可考虑引入更强的正则化或采用更大规模的预训练语料以进一步提升泛化能力。此外，本文的实验设计也为注意力机制的进一步改进提供了经验依据。

参考文献

- [1] Goodfellow I, Bengio Y, Courville A. Deep Learning. MIT Press, 2016.
- [2] Bahdanau D, Cho K, Bengio Y. Neural Machine Translation by Jointly Learning to Align and Translate. International Conference on Learning Representations, 2015.
- [3] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need. Advances in Neural Information Processing Systems, 2017.
- [4] Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. North American Chapter of the Association for Computational Linguistics, 2019.
- [5] Radford A, Narasimhan K, Salimans T, et al. Improving Language Understanding by Generative Pre-Training. OpenAI Technical Report, 2018.
- [6] Gehring J, Auli M, Grangier D, et al. Convolutional Sequence to Sequence Learning. International Conference on Machine Learning, 2017.
- [7] Tatoeba Project. Tatoeba Sentence Pairs Dataset. <https://tatoeba.org/>, 2024.
- [8] Papineni K, Roukos S, Ward T, et al. BLEU: a Method for Automatic Evaluation of Machine Translation. Association for Computational Linguistics, 2002.
- [9] Kingma D P, Ba J. Adam: A Method for Stochastic Optimization. International Conference on Learning Representations, 2015.